

Questionário (ref. Aulas 10 a 18)

Capítulo IV – SVM

- 1) Qual é a principal diferença entre Regressão Logística e SVM com relação à forma como a classificação é realizada e à interpretação probabilística das previsões em classificação supervisionada?

A regressão logística busca modelar probabilidades das classes, permitindo interpretar a confiança da previsão. Já o SVM busca maximizar geometricamente a margem de separação entre as classes, priorizando robustez da fronteira de decisão. Em muitos problemas de PLN ambos podem gerar fronteiras lineares semelhantes, mas a regressão logística é probabilística enquanto o SVM é orientado à separação máxima. O SVM clássico apenas define de que lado da fronteira o ponto caiu e qual sua distância da margem. Ele não nasce probabilístico.

- 2) O que são vetores de suporte no SVM?

Vetores de suporte são os pontos mais próximos da fronteira de decisão. Eles são importantes porque definem a margem máxima de separação entre as classes e influenciam diretamente a posição do hiperplano.

- 3) O que representa a margem máxima no SVM e por que ela é importante?

A margem é a distância entre o hiperplano de decisão e os vetores de suporte mais próximos. O SVM busca maximizar essa margem porque fronteiras mais afastadas das amostras tendem a apresentar melhor capacidade de generalização para novos dados. A maximização da margem é o princípio central do SVM. Enquanto o KNN toma decisões com base na distância entre vizinhos e a Regressão Logística busca modelar probabilidades por meio de uma fronteira de decisão linear, o SVM procura encontrar a fronteira que produz a maior margem possível entre as classes. Por isso, a margem máxima é o conceito fundamental do SVM.

- 4) Por que kernels lineares costumam ser suficientes em problemas de PLN quando se usa SVM com TF-IDF ou BoW?

Porque representações como TF-IDF e BoW já projetam os documentos em espaços de alta dimensionalidade, nos quais a separação linear costuma ser suficiente.

- 5) Explique o Kernel Trick no SVM.

O Kernel Trick é um mecanismo que permite ao SVM operar como se os dados estivessem em um espaço de maior dimensão sem realizar explicitamente essa transformação. Isso possibilita separar dados não linearmente separáveis.

Questionário (ref. Aulas 10 a 18)

Capítulo IV – LDA

6) Explique o que é o LDA ?

O LDA (Latent Dirichlet Allocation) é um modelo probabilístico generativo de machine learning não supervisionado utilizado para identificar tópicos latentes em um conjunto de documentos. Ele representa cada documento como uma mistura de tópicos e cada tópico como uma distribuição probabilística de palavras. O modelo busca descobrir automaticamente padrões de coocorrência de termos no corpus, sem utilizar rótulos previamente definidos.

7) Explique como o LDA representa os documentos e os tópicos, destacando por que um mesmo documento pode estar associado simultaneamente a múltiplos tópicos.

O LDA representa cada documento como uma mistura probabilística de tópicos e cada tópico como uma distribuição probabilística de palavras. Isso significa que um mesmo documento pode conter diferentes temas simultaneamente, cada um com determinado peso ou probabilidade. O modelo identifica esses tópicos automaticamente a partir de padrões de coocorrência de palavras no corpus, sem utilizar rótulos.

8) O que representa $P(\text{palavra} | \text{tópico})$ no LDA?

$P(\text{palavra} | \text{tópico})$ representa a probabilidade de uma palavra aparecer em determinado tópico, indicando o quanto aquela palavra caracteriza o tópico.

9) Qual é o principal hiperparâmetro do LDA?

O hiperparâmetro mais importante do LDA costuma ser o número de tópicos K (embora haja outros que não vimos a fundo).

10) O que acontece quando K é muito alto no LDA?

Valores muito altos de K podem gerar tópicos excessivamente específicos, redundantes ou pouco interpretáveis.

11) O que significa dizer que o LDA opera sobre Bag-of-Words?

Significa que o LDA desconsidera a ordem das palavras e utiliza apenas suas frequências no documento para identificar padrões de coocorrência e inferir tópicos.

Questionário (ref. Aulas 10 a 18)

Capítulo IV – K-Means

12) Qual é a principal finalidade do K-Means?

A principal finalidade do K-Means é realizar agrupamento não supervisionado de dados com base em similaridade. O algoritmo busca formar clusters internamente homogêneos e externamente bem separados, agrupando pontos próximos em torno de centroides. Cada cluster é representado por um centroide, calculado como a média dos pontos pertencentes ao grupo.

13) Explique resumidamente o ciclo iterativo do K-Means.

O K-Means começa definindo o número de clusters K e inicializando centroides. Em seguida, cada ponto é associado ao centroide mais próximo. Após essa associação, os centroides são recalculados como a média dos pontos de cada cluster. Esse processo de associação e recálculo é repetido iterativamente até que os centroides parem de mudar significativamente, o algoritmo convirja ou seja atingido um limite de iterações.

14) Por que o número de clusters K deve ser definido antes da execução do algoritmo?

Porque o K-Means é um algoritmo particional que necessita conhecer previamente quantos grupos deve formar. A escolha inadequada de K pode produzir agrupamentos artificiais ou ocultar estruturas relevantes existentes nos dados.

15) O que a função custo J mede no K-Means?

A função custo J mede o erro total do agrupamento no K-Means. Ela corresponde à soma das distâncias quadráticas entre cada ponto e o centroide do seu respectivo cluster. O objetivo do algoritmo é minimizar esse valor, produzindo grupos mais compactos e coerentes. Quanto menor o valor de J , menor a dispersão interna dos clusters.

16) Explique o que é método do cotovelo.

O método do cotovelo é uma técnica utilizada para auxiliar na escolha do número ideal de clusters K no K-Means. O procedimento consiste em executar o algoritmo para diferentes valores de K e observar o comportamento da função custo J . À medida que K aumenta, o erro tende a diminuir. O ponto em que a redução do erro começa a desacelerar significativamente forma um “cotovelo” no gráfico, indicando um equilíbrio entre qualidade do agrupamento e complexidade do modelo.

17) Qual a vantagem do K-Means++ sobre inicialização aleatória?

Questionário (ref. Aulas 10 a 18)

O K-Means++ melhora a escolha inicial dos centroides ao selecionar pontos mais distantes entre si de maneira estratégica. Isso reduz a probabilidade de inicializações ruins, melhora a qualidade final dos clusters e acelera a convergência do algoritmo. Além disso, diminui a probabilidade de convergência para soluções locais de baixa qualidade.

18) O parâmetro `n_init` no K-Means serve para quê?

O parâmetro `n_init` define quantas vezes o algoritmo será executado utilizando diferentes inicializações dos centroides. Como o resultado do K-Means depende da posição inicial dos centroides, múltiplas execuções ajudam a reduzir o risco de soluções ruins. Ao final, o algoritmo seleciona a solução que apresentou o menor valor da função custo J .

19) Cite duas limitações importantes do K-Means.

O algoritmo é sensível à inicialização dos centroides, podendo convergir para soluções ruins dependendo dos valores iniciais escolhidos. Além disso, assume clusters aproximadamente convexos e de tamanhos semelhantes, o que dificulta sua aplicação em dados com formatos complexos ou distribuições irregulares. O modelo também é sensível a outliers, que podem deslocar significativamente os centroides.

20) Explique o que é o Rand Index.

O Rand Index é uma métrica utilizada para avaliar a similaridade entre dois agrupamentos. Ele compara os clusters produzidos pelo algoritmo com uma referência de classes reais, analisando pares de elementos e verificando se eles foram agrupados de maneira consistente nos dois agrupamentos. Seus valores variam de 0 a 1, sendo que valores próximos de 1 indicam maior concordância.

21) Por que o ARI é considerado melhor que o RI?

O ARI (Adjusted Rand Index) é considerado melhor que o RI porque corrige o efeito do acaso na avaliação dos agrupamentos. Enquanto o RI tradicional pode apresentar valores elevados mesmo em agrupamentos parcialmente aleatórios, o ARI ajusta estatisticamente essa expectativa, tornando a avaliação mais confiável e rigorosa.

22) Considerando que o K-Means é um algoritmo não supervisionado, explique por que métricas como Rand Index e Adjusted Rand Index dependem da existência de rótulos de referência.

O K-Means é considerado não supervisionado porque realiza agrupamentos sem utilizar rótulos durante o treinamento. Entretanto, métricas como Rand Index e Adjusted Rand Index são métricas de avaliação externa, utilizadas após a clusterização para comparar os clusters gerados com classes reais previamente conhecidas. Assim, embora

Questionário (ref. Aulas 10 a 18)

o algoritmo não utilize supervisão para formar os grupos, essas métricas dependem de rótulos de referência para medir a qualidade do agrupamento produzido.

23) O Silhouette Score avalia quais dois aspectos simultaneamente?

O Silhouette Score avalia simultaneamente dois aspectos: a coesão interna e a separação entre clusters. A coesão mede o quão próximos os pontos estão dentro do próprio cluster, enquanto a separação mede o quão distantes eles estão dos outros clusters. Dessa forma, a métrica avalia se os grupos estão compactos internamente e bem separados externamente.

Questionário (ref. Aulas 10 a 18)

Capítulo IV – Word2Vec

24) Que limitações do BoW/TF-IDF o Word2Vec tenta resolver?

O Word2Vec surgiu para superar limitações de BoW e TF-IDF, que tratam palavras como unidades independentes e dependem da frequência ou da presença exata dos termos. Essas representações não capturam bem sinonímia nem relações semânticas latentes e possuem limitações para representar diferentes significados de uma mesma palavra em contextos distintos. O Word2Vec passa a representar palavras por vetores aprendidos a partir do contexto em que aparecem.

25) Explique por que palavras semanticamente semelhantes tendem a possuir vetores próximos no Word2Vec.

No Word2Vec, palavras semanticamente semelhantes tendem a ter vetores próximos porque aparecem em contextos parecidos. O modelo aprende que termos usados em ambientes linguísticos semelhantes possuem relação de significado, convertendo essa proximidade contextual em proximidade geométrica no espaço vetorial.

26) Qual a diferença entre os modelos CBOW e Skip-gram no Word2Vec.

No CBOW, o modelo tenta prever a palavra central a partir das palavras vizinhas. No Skip-gram, o modelo recebe a palavra central e tenta prever as palavras do contexto. Assim, CBOW usa o contexto para prever a palavra; Skip-gram usa a palavra para prever o contexto.

27) Explique a arquitetura da rede neural utilizada no Word2Vec, descrevendo o papel das camadas de entrada, projeção e saída.

O Word2Vec utiliza uma rede neural rasa (shallow) composta por três camadas: entrada, projeção e saída. A camada de entrada recebe a palavra representada normalmente por um vetor one-hot. Em seguida, essa representação é projetada para um espaço vetorial de menor dimensão por meio da camada intermediária, também chamada de camada de projeção. Os pesos dessa camada correspondem aos embeddings aprendidos. Por fim, a camada de saída tenta prever palavras do contexto ou a palavra central, dependendo da arquitetura utilizada (CBOW ou Skip-gram), geralmente utilizando softmax para calcular probabilidades sobre o vocabulário.

28) Explique como funciona a rede neural utilizada no Word2Vec. (1,0)

O Word2Vec utiliza uma rede neural rasa composta por camada de entrada, camada intermediária de projeção e camada de saída. O modelo aprende representações vetoriais das palavras realizando tarefas de predição baseadas no contexto, como prever a palavra central ou as palavras vizinhas.

Questionário (ref. Aulas 10 a 18)

29) Em qual parte da arquitetura do Word2Vec os embeddings são aprendidos? (1,0)

Os embeddings são aprendidos principalmente na camada intermediária, também chamada de camada de projeção.

30) Qual é a principal função da camada de saída no Word2Vec? (1,0)

A camada de saída tem a função de prever palavras do contexto ou a palavra central, dependendo da arquitetura utilizada, normalmente utilizando softmax para calcular probabilidades sobre o vocabulário.

31) Explique em qual parte da arquitetura do Word2Vec o embedding aprendido é obtido e qual o papel dessa camada no modelo.

O embedding aprendido corresponde principalmente à camada intermediária, também chamada de camada de projeção. A entrada é uma representação one-hot, que é projetada para um espaço vetorial menor. Os pesos dessa camada formam os vetores densos que representam semanticamente as palavras.

32) Explique o que o parâmetro window controla no Word2Vec e como ele influencia o aprendizado semântico.

O parâmetro window define o tamanho da janela de contexto utilizada pelo Word2Vec, ou seja, quantas palavras vizinhas serão consideradas ao redor da palavra central. Janelas menores tendem a capturar relações mais locais e sintáticas, enquanto janelas maiores capturam relações semânticas mais amplas.

33) Explique o significado do parâmetro sg no Word2Vec e como ele define o funcionamento do modelo.

O parâmetro sg define qual arquitetura será utilizada no Word2Vec. Quando $sg = 0$, utiliza-se CBOW, que prevê a palavra central a partir do contexto. Quando $sg = 1$, utiliza-se Skip-gram, que prevê o contexto a partir da palavra central.

34) Explique o que representa o parâmetro vector_size no Word2Vec.

O parâmetro vector_size representa a dimensão dos embeddings aprendidos pelo modelo, isto é, o tamanho do vetor numérico utilizado para representar cada palavra no espaço vetorial.

35) Explique a função do parâmetro min_count no Word2Vec e sua relação com o vocabulário do modelo.

Define a frequência mínima necessária para que uma palavra seja incluída no vocabulário do Word2Vec. Palavras que aparecem menos vezes do que esse limite são descartadas durante a construção do modelo. Isso reduz ruído causado por termos muito raros, diminui o tamanho do vocabulário e

Questionário (ref. Aulas 10 a 18)

melhora a eficiência computacional. Além disso, palavras com poucas ocorrências geralmente não possuem contexto suficiente para que embeddings semanticamente confiáveis sejam aprendidos.

36) Qual é a função do softmax durante o treinamento do Word2Vec.
O softmax transforma os escores produzidos pela rede em uma distribuição de probabilidades sobre todas as palavras do vocabulário. Durante o treinamento, o modelo ajusta seus pesos para aumentar a probabilidade das palavras corretas e reduzir a das incorretas.

37) O que significa afirmar que o Word2Vec representa palavras geometricamente?
Significa que cada palavra passa a ser representada por um vetor em um espaço multidimensional. Palavras semanticamente semelhantes tendem a ocupar regiões próximas desse espaço vetorial

38) Explique o conceito de similaridade do cosseno no contexto de embeddings e sua utilidade na comparação entre palavras.
A similaridade do cosseno é uma métrica utilizada para medir o grau de proximidade entre dois vetores considerando o ângulo entre eles. No contexto de embeddings, ela é utilizada para comparar palavras representadas vetorialmente no espaço semântico aprendido pelo modelo. Quanto mais próximo de 1 for o valor do cosseno, mais semelhantes semanticamente tendem a ser as palavras. Essa métrica é amplamente utilizada porque avalia a direção dos vetores, reduzindo o impacto da magnitude absoluta dos embeddings.

39) Qual é a principal limitação do Word2Vec em relação à polissemia?
O Word2Vec atribui apenas um vetor para cada palavra. Assim, palavras com múltiplos significados, como "banco", recebem a mesma representação vetorial independentemente do contexto em que aparecem.

40) Qual é o principal produto final obtido após o treinamento do Word2Vec?
O principal resultado do Word2Vec são os embeddings das palavras. Embora o treinamento utilize tarefas de predição, o objetivo final não é prever palavras, mas aprender vetores densos capazes de representar relações semânticas e sintáticas entre os termos do vocabulário. Para isso, a rede neural ajusta iterativamente seus pesos durante o treinamento. Quando o processo converge, os pesos aprendidos na matriz de projeção passam a constituir os embeddings das palavras. Assim, cada linha (ou coluna, dependendo da implementação) dessa matriz corresponde ao vetor que representa uma palavra do vocabulário.

Questionário (ref. Aulas 10 a 18)

Capítulo IV – BERT e SBERT

41) Qual limitação importante do Word2Vec motivou o surgimento de modelos como o BERT?

O Word2Vec atribui um único vetor fixo para cada palavra do vocabulário. Embora o contexto seja utilizado durante o treinamento, a palavra recebe apenas uma representação vetorial, independentemente do significado assumido em cada frase. Isso dificulta o tratamento de fenômenos como polissemia e dependência de contexto. Modelos como o BERT surgiram para gerar representações contextuais, nas quais uma mesma palavra pode receber embeddings diferentes dependendo das demais palavras presentes na sentença.

42) O que é o BERT?

O BERT (Bidirectional Encoder Representations from Transformers) é um modelo de PLN baseado na arquitetura Transformer. Seu objetivo é aprender representações profundas da linguagem utilizando mecanismos de self-attention e treinamento bidirecional.

43) O que significa dizer que o BERT produz representações contextuais?

Significa que a representação vetorial de uma palavra depende do contexto em que ela aparece. Assim, a mesma palavra pode receber embeddings diferentes em frases distintas. Isso permite que o modelo diferencie significados conforme o uso da palavra dentro da sentença.

44) O que é self-attention?

Self-attention é o mecanismo que permite que cada token da sequência analise os demais tokens da mesma sequência ao construir sua representação. Dessa forma, o modelo consegue identificar quais palavras são mais relevantes para interpretar o significado de cada termo dentro do contexto da frase.

45) Qual é a principal diferença entre Word2Vec e BERT?

O Word2Vec produz embeddings fixos para palavras individuais, enquanto o BERT produz embeddings contextuais. No Word2Vec, cada palavra possui um único vetor. No BERT, a representação da palavra depende da frase em que ela aparece, permitindo capturar contexto, ambiguidades e relações linguísticas mais complexas.

46) O que é o SBERT?

O SBERT (Sentence-BERT) é uma adaptação do BERT desenvolvida especificamente para gerar embeddings de sentenças e documentos. Seu objetivo é produzir vetores que representem diretamente o significado

Questionário (ref. Aulas 10 a 18)

global de um texto, permitindo comparações eficientes por similaridade semântica.

47) Qual problema do BERT tradicional o SBERT procura resolver?

Embora o BERT produza representações contextuais de alta qualidade, ele não foi originalmente projetado para comparar textos diretamente. O SBERT foi treinado para gerar embeddings que possam ser comparados por similaridade de cosseno, tornando tarefas como busca semântica, clustering e recomendação muito mais eficientes.

48) Por que a similaridade do cosseno é amplamente utilizada com SBERT?

Porque os embeddings produzidos pelo SBERT são treinados para que textos semanticamente semelhantes fiquem próximos no espaço vetorial. A similaridade do cosseno mede o ângulo entre vetores e permite quantificar o grau de proximidade semântica entre sentenças ou documentos.

49) Cite três aplicações típicas do SBERT.

O SBERT é amplamente utilizado em busca semântica, clustering de textos, sistemas de recomendação, recuperação de informação, deduplicação de documentos e comparação de similaridade textual. Essas aplicações exploram a capacidade do modelo de representar o significado global dos textos em vetores comparáveis.

50) Cite uma vantagem e uma limitação do SBERT.

A principal vantagem é sua capacidade de capturar contexto e significado de forma mais precisa que TF-IDF ou Word2Vec. Como limitação, o modelo possui maior custo computacional, exige mais memória e depende de modelos pré-treinados relativamente grandes para funcionar adequadamente.